

Inteligência Artificial

ACH2016

Aula 6: Busca local

Profa. Karina Valdivia Delgado
EACH-USP

Slides baseados em:

RUSSEL, S.; NORVIG, P. Artificial Intelligence: A modern approach. Third Edition, 2010. Capítulo 4.

Slides do Prof. Edirlei Soares de Lima

Slides da Profa. Leliane Nunes de Barros

Métodos de busca

- **Busca sem informação ou cega ou exaustiva ou força bruta ou sistemática :**
 - Não sabe qual o melhor nó da fronteira a ser expandido. Apenas distingue o estado objetivo dos não objetivos.
- **Busca informada ou heurística:**
 - Estima qual o melhor nó da fronteira a ser expandido com base em funções heurísticas. Sabem se um estado não objetivo é “mais promissor”.
- **Busca local:**
 - Operam em um único estado e movem-se para a vizinhança deste estado.

Busca local

- Em muitos problemas o **caminho para a solução é irrelevante**.
 - **Jogo das n-rainhas:** o que importa é a configuração final e não a ordem em que as rainhas foram acrescentadas.
 - **Outros exemplos:**
 - Projeto de Circuitos eletrônicos;
 - Roteamento de veículos;
 - Escalonamento de salas de aula;
 - Otimização de redes;

Busca local

- Algoritmos de busca local operam sobre um **único estado corrente**, ao invés de vários caminhos.
- Em geral se movem apenas para os **vizinhos** desse estado.
- O caminho seguido pelo algoritmo não é guardado.

Busca local


- **Vantagens:**
 - Ocupam pouquíssima memória (normalmente constante).
 - Podem encontrar soluções razoáveis em grandes ou infinitos espaços de estados.
- **São uteis para resolver problemas de otimização.**
 - Buscar por estados que atendam a uma **função objetivo**.

Busca local

- **Topologia do espaço de estados:** o algoritmo de busca local explora essa topologia
- **Posição** = Estado;

Elevação = valor da **função objetivo** ou valor da função de custo da heurística;

- Busca-se o **máximo** ou mínimo global;



Busca local

- **Principais Algoritmos:**
 - Hill Climbing
 - Simulated Annealing
 - Genetic Algorithms

Pseudocódigo – Hill Climbing

Função Hill-Climbing(*Problema*) **retorna** um estado que é um máximo local

EstadoAtual ← **CRIAR-NÓ**(*Problema*.EstadoInicial)

repita

Vizinho ← SucessorDeMaiorValor(EstadoAtual)

se Vizinho.Valor for menor ou igual EstadoAtual.Valor **então**


retorna EstadoAtual

EstadoAtual ← Vizinho

- O algoritmo move-se continuamente para os estados que aumentam o valor.
- Termina quando atinge um "pico" onde nenhum vizinho tem um valor maior.
- Não mantém uma árvore de busca.

Hill Climbing: exemplo

- **Problema:** 8 Rainhas (estados completos)
 - Em cada estado: 8 rainhas no tabuleiro, uma em cada coluna.
- **Ações:**
 - Mover uma rainha para outro quadrado na mesma coluna.
- **Função Heurística (h):**
 - Número de pares de rainhas que estão sendo atacadas umas às outras.
- **Objetivo:**
 - $h = 0$ (nenhuma rainha sendo atacada)



Hill Climbing:exemplo

- **$h = 17$**
- Melhor movimento: 12

Valores de seus sucessores

18	12	14	13	13	12	14	14
14	16	13	15	12	14	12	16
14	12	18	13	15	12	14	14
15	14	14	♠	13	16	13	16
♠	14	17	15	♠	14	16	16
17	♠	16	18	15	♠	15	♠
18	14	♠	15	15	14	♠	16
14	14	13	17	12	14	12	18

Hill Climbing: exemplo

- **$h = 17$**
- Melhor movimento: 12


18	12	14	13	13	12	14	14
14	16	13	15	12	14	12	16
14	12	18	13	15	12	14	14
15	14	14	♔	13	16	13	16
♔	14	17	15	♔	14	16	16
17	♔	16	18	15	♔	15	♔
18	14	♔	15	15	14	♔	16
14	14	13	17	12	14	12	18

Se movimentamos a rainha da coluna 4 para essa posição temos $h=17-2=15$

Hill Climbing: exemplo


18	12	14	13	13	12	14	14
14	16	13	15	12	14	12	16
14	12	18	13	15	12	14	14
15	14	14	♔	13	16	13	16
♔	14	17	15	♔	14	16	16
17	♔	16	18	15	♔	15	♔
18	14	♔	15	15	14	♔	16
14	14	13	17	12	14	12	18

- Em 5 passos alcança o estado com $h=1$ (mínimo local para o custo h)



Hill Climbing

- É um **algoritmo guloso** – escolhe sempre o primeiro melhor vizinho para progredir na busca.
- Essa abordagem pode ter **bons resultados em alguns problemas**. Sendo capaz de progredir rapidamente para a solução problema.
- Mas, pode ficar paralisada pelas seguintes razões:
 - Máximos locais: Pico mai alto que cada um de seus estados vizinhos. O algoritmo fica preso.
 - Platôs: Áreas planas. O algoritmo tal platô.
 - Máximo local plano
 - Planície



Hill Climbing – Exemplo

- **Problema:** 8 Rainhas
- **Inicializando aleatoriamente o estado inicial:**
 - O algoritmo fica **preso em um máximo local** em 86% das vezes.
 - Resolve apenas 14% das instancias.
- Quando tem sucesso, resolve o problema em **aproximadamente 4 passos** – nada mal para um espaço de estados com 17 milhões de estados.

Hill Climbing

Não é ótimo e não é completo.

O desempenho do Hill Climbing depende muito do **formato da topologia** do espaço de estados.

- **Variações:**


Random-Restart Hill Climbing;

Random-restart Hill-climbing

- Execute uma série de buscas hill-climbing a partir de um estado inicial aleatório.
- Guarda o melhor resultado.
- Pode usar um número fixo de iterações ou continuar até não conseguir superar o melhor resultado guardado considerando um certo número de iterações.
- Sucesso depende da forma da superfície.

Simulated annealing

- Tenta combinar o Hill-climbing com um percurso aleatório.
- *Annealing*: processo de resfriamento de metais (envolve Temperatura, Tempo, Energia).




Simulated annealing

- Tenta combinar o Hill-climbing com um percurso aleatório.

- *Annealing*: processo de resfriamento de metais (envolve Temperatura, Tempo, Energia)


Queremos minimizar o custo



Simulated annealing

- Tenta combinar o Hill-climbing com um percurso aleatório.
- *Annealing*: processo de resfriamento de metais (envolve Temperatura, Tempo, Energia)


Queremos colocar a bola no lugar mais profundo



Simulated annealing

- Tenta combinar o Hill-climbing com um percurso aleatório.
- *Annealing*: processo de resfriamento de metais (envolve Temperatura, Tempo, Energia)


Se deixamos a bola rolar, acaba em um mínimo local



Simulated annealing

- Tenta combinar o Hill-climbing com um percurso aleatório.
- *Annealing*: processo de resfriamento de metais (envolve Temperatura, Tempo, Energia)


Se agitamos a superfície podemos fazer com que a bola saia do mínimo local



Simulated annealing


- Tenta combinar o Hill-climbing com um percurso aleatório.
- *Annealing*: processo de resfriamento de (envolve Temperatura, Tempo, Energia)

O algoritmo começa agitando com força (alta temperatura) e depois reduz gradualmente a intensidade (baixando a temperatura).



Simulated annealing

- Ao invés de começar de novo permite que a busca suba o “morro” alguns paços, i.e, piora para depois melhorar.
- Pulo no espaço de estados não totalmente aleatório.
- Decresce gradualmente o tamanho do pulo e a frequência até alcançar o melhor estado.



Simulated annealing

Função Simulated-Annealing (*problema*, *escala*) **retorna** *um estado solução*

Entradas: *problema*

escala: um mapeamento de tempo para "temperatura"

estado-corrente \leftarrow **CRIAR-NÓ**(*problema*. Estado-Inicial)

para $t = 1$ **to** infinito **faça**

$T \leftarrow$ *escala*[t]

se $T = 0$ **então retorna** *estado-corrente*

próximo-estado \leftarrow *seleção aleatória de um sucessor do estado-corrente*

$\Delta E \leftarrow$ *próximo-estado*.Valor – *estado-corrente*.Valor

se $\Delta E > 0$ **então** *estado-corrente* \leftarrow *próximo-estado*

senão *estado-corrente* \leftarrow *próximo-estado* com probabilidade $e^{\Delta E/T}$

Simulated annealing

Temperatura

Função Simulated-Annealing (*problema*, *escala*) **retorna** *estado-corrente*

Entradas: *problema*

escala: um mapeamento do tempo para "temperatura"

estado-corrente \leftarrow **CRIAR-NÓ**(*problema*. Estado-Inicial)

para $t = 1$ **to** infinito **faça**

$T \leftarrow$ *escala*[t]

se $T = 0$ **então retorna** *estado-corrente*

próximo-estado \leftarrow seleção aleatória de um sucessor do *estado-corrente*

$\Delta E \leftarrow$ *próximo-estado*.Valor – *estado-corrente*.Valor

se $\Delta E > 0$ **então** *estado-corrente* \leftarrow *próximo-estado*

senão *estado-corrente* \leftarrow *próximo-estado* com probabilidade $e^{\Delta E/T}$

Simulated annealing

Se o movimento melhora a situação, vai para o próximo estado (o movimento é aceito)

Função Simulated-Annealing (*problema*, *escala*) **retorna**

Entradas: *problema*

escala: um mapeamento de tempo para "temperatura"

estado-corrente \leftarrow CRIAR-NÓ(*problema*. Estado-Inicial)

para $t = 1$ **to** infinito **faça**

$T \leftarrow$ *escala*[t]

se $T = 0$ **então retorna** *estado-corrente*

próximo-estado \leftarrow seleção aleatória de um sucessor de *estado-corrente*

$\Delta E \leftarrow$ *próximo-estado*.Valor – *estado-corrente*.Valor

se $\Delta E > 0$ **então** *estado-corrente* \leftarrow *próximo-estado*

senão *estado-corrente* \leftarrow *próximo-estado* com probabilidade $e^{\Delta E/T}$

Simulated annealing

Função Simulated-Annealing (*problema*, *escala*) **re**

Entradas: *problema*

escala: um mapeamento de tempo pa

estado-corrente \leftarrow **CRIAR-NÓ**(*problema*. Estado-In

para $t = 1$ **to** infinito **faça**

$T \leftarrow$ *escala*[t]

se $T = 0$ **então retorna** *estado-corrente*

próximo-estado \leftarrow seleção aleatória de um sucessor do *estado-corrente*

$\Delta E \leftarrow$ *próximo-estado*.Valor – *estado-corrente*.Valor

se $\Delta E > 0$ **então** *estado-corrente* \leftarrow *próximo-estado*

senão *estado-corrente* \leftarrow *próximo-estado* com probabilidade $e^{\Delta E/T}$

Senão aceitará o movimento que piora a situação (vai para um próximo estado pior) com probabilidade $e^{\Delta E/T}$; e com probabilidade $1 - e^{\Delta E/T}$ fica no mesmo estado.

Simulated annealing

Uma vez ΔE é negativo e $T \geq 0$ (i.e., o expoente de e é negativo), a probabilidade decresce à medida que $\Delta E/T$ se reduz.

Função Simulated-Annealing (*problema*, *escala*) **retorna**

Entradas: *problema*

escala: um mapeamento de tempo para "temperatura"

estado-corrente \leftarrow **CRIAR-NÓ**(*problema*. Estado-Inicial)

para $t = 1$ **to** infinito **faça**

$T \leftarrow$ *escala*[t]


se $T = 0$ **então retorna** *estado-corrente*

próximo-estado \leftarrow seleção aleatória de um sucessor do *estado-corrente*

$\Delta E \leftarrow$ *próximo-estado*.Valor – *estado-corrente*.Valor

se $\Delta E > 0$ **então** *estado-corrente* \leftarrow *próximo-estado*

senão *estado-corrente* \leftarrow *próximo-estado* com probabilidade $e^{\Delta E/T}$



Busca local

- **Principais Algoritmos:**
 - Hill Climbing
 - Simulated Annealing
 - Genetic Algorithms